

一、业务目标阐述

本次分析的业务目标主要是帮助集团细分顾客群体，通过识别不同顾客群体在消费结构、购物偏好、消费渠道上的差异，进行精准的业务决策和营销。

基于零售业务的实际需求，本次分析希望得到 3-5 类顾客群体，这样既可以体现顾客群体之间的差异性，又不会让后续营销活动的执行成本过高，管理太过复杂。

经过细分顾客群体，希望可以给不同消费偏好的客群设计差异化的促销活动，以提升转化率、降低发券成本；结合忠诚度评分识别出客户价值，进一步优化会员分级体系，对不同客群制定相应的服务策略；根据客群线上线下的购物偏好分配合适的渠道资源，优化线上推荐和线下门店陈列策略，实现各渠道协同增长。

二、特征选择与数据预处理

为识别顾客的消费行为模式，本研究选择反映消费结构和购物活跃度的行为变量作为聚类输入，包括各类消费支出以及线上和线下访问频率，具体特征如表 1 所示。这些变量能够直接刻画顾客的消费等级、购物偏好和活跃程度，是识别顾客价值和消费行为模式差异的核心依据。

人口统计变量（age、gender、marital_status、education_level、monthly_income、num_children）不参与聚类，仅用于后续客户画像分析，以帮助解释不同客户群体的特征。loyalty_score 是由消费额和访问次数衍生的指标，本次分析中被用于业务验证，以评估不同客户群体在客户忠诚度和潜在商业价值上的差异，从而判断聚类结果是否具有实际业务意义。customer_id 没有实际意义，在本次分析中剔除。

表 1 特征统计表

特征	含义	特征类别	用途
spend_grocery	日常杂货支出	数值特征	行为变量 作为聚类 输入
spend_fashion	服饰支出	数值特征	
spend_electronics	电子产品支出	数值特征	
spend_dining	外出就餐支出	数值特征	
spend_online	线上购物支出	数值特征	
visits_store_per_month	线下门店月平均到访次数	数值特征	
visits_online_per_month	线上平台月平均访问次数	数值特征	

age	年龄	数值特征	只用于画像，不参与聚类
gender	性别	数值特征	
marital_status	婚姻状况	类别特征	
education_level	学历	类别特征	
monthly_income	月收入(SGD)	数值特征	
num_children	子女数量	数值特征	业务验证，判断聚类结果是否具有实际业务意义
loyalty_score	忠诚度评分，由访问次数和消费额决定	数值特征（指标型数据）	

本研究中共有 2000 条数据，如图 1 数值变量普遍呈右偏分布并存在长尾特征。monthly_income、num_children、spend_electronics、spend_online4 个数值变量存在少量缺失值，缺失比例为 2.5%，采用中位数填充方法，以提高稳健性并避免极端值干扰。各特征数值范围差异较大，选用 StandardScaler 做标准化处理，解决量纲不一致问题。

中位数填充在不删除缺失值样本的基础上，也避免了人为拉高缺失用户的消费水平。标准化的处理方法有助于在降维过程中有效压缩图 2 中所示相关性较高的特征组（ $r=0.51$ ），最终提取出有区分度的潜在维度，在欧氏距离计算中也更公平，避免高数值变量主导聚类结果。




图 1




图 2

三、PCA 降维与主成分解释

用解释方差比、轮廓系数、MSE 三个指标，从信息保留和聚类质量两个方面对 PC3 和 PC5 进行对比，对比结果如表 2。

表 2 PC3 和 PC5 对比

主成分个数	累计解释方差比	轮廓系数	MSE
PC3	67.49%	0.4475	0.3251
PC5	85.38%	0.3212	0.1462

PC3 的轮廓系数更高（0.4475），簇间分离更清晰，但从图 3 中可以看到，PC3 仅保留了 67.49%的原始信息，约三分之一的信息在降维中丢失，这可能影响后续对客户群体的完整刻画。PC5 保留了 85.38%的原始信息，而且 MSE 更小（0.1462），但轮廓系数下降至 0.3212，这意味着额外引入的维度带来了噪声，削弱了聚类的分离度。




图 3

虽然 PC3 的轮廓系数更高，但本研究中选择 PC5。主要是因为 PC5 不仅保留了 85.38%的原始信息，轮廓系数也在 30%以上的可接受范围，是兼顾信息完整性与聚类有效性的最佳选择。

图 4 列出了前三个主成分的载荷情况。




图 4

PC1 上载荷较大的特征涵盖线上访问频次、线上消费、时尚、餐饮、电子，方向高度一致，spend_grocery 为轻微负值。PC1 代表的是线上访问频繁、消费高、偏好时尚和餐饮的活跃消费者。

PC2 上杂货消费和线下到店频次为强正载荷，线上访问频次和线上消费为负

载荷。PC2 代表的是频繁到店、偏好生鲜杂货和线下餐饮，线上活跃度相对较低的传统消费者。

PC3 由 visits_store_per_month 主导，载荷高达+0.855，远超其他特征，而各消费金额变量为负或载荷较低。这说明 PC3 捕捉的是一种特殊行为模式：到店频次极高但各品类消费金额反而偏低，是典型的高频率低消费行为，可能是日常小额采购的用户群体，与 PC1 描述的"高消费活跃客户"形成鲜明对比。

四、在主成分空间上使用 K-Means 聚类

保留 PC5 作为聚类输入特征，使用 K-Means 进行聚类分析。对 K=2 到 K=18 进行 Inertia、Silhouette Score、CHI、DBI 和 Stability 等指标计算，指标结果如图 5 至图 7 所示。Inertia 在 K=4 后曲线趋于平缓，肘点不明显，但 K=3 至 4 是拐点区域；Silhouette 在 K=3 时最高（0.333），K=4 次之，之后单调下降。CHI 在 K=4 达到峰值后持续下降；DBI 在 K=3 最低（0.93），K=4 时虽略上升，但相对来说仍处于低位。ARI 最佳选择应为 K=2、4、6。综合以上指标，K=3 或 K=4 为最优选择。




图 5




图 6




图 7

对 K=3 和 K=4 进行聚类分析，从表 3 中可以看到两种分类方式都分类出了只有 15 人的一个簇，区别在于主体客户的分类上。

根据图 8、图 9 数据来看，K=3 时主体客户分类为簇 0（低消费线下型）和簇 1（高消费线上型）；K=4 时主体客户得到进一步细分，分类出簇 0（线下实体消费型）、簇 1（线上线下均冷淡的低活跃低消费型）、簇 2（线上时尚消费型）。

表 3 K=3 和 K=4 聚类结果对比

聚类数	簇	数量	占比
K=3	0	913	0.456
	1	1072	0.536
	2	15	0.008
---	---	---	---
K=4	0	628	0.314
	1	466	0.233
	2	891	0.446
	3	15	0.008

从图 10 来看，K=3 时主体客户的分类会太过粗糙，对中间交界处的人群区分不够，簇 0 中间有明显稀疏区域，在业务上制定差异化策略时难以实现精准营

销；而 K=4 时主体客户分类出三个规模合理、特征鲜明的群体，可直接支撑差异化运营策略（如对簇 2 推送线上时尚促销，对簇 0 加强线下门店体验，对簇 1 做激活召回）。综合评估指标、业务可解释性与可操作性，本研究最终选择 K=4。

[K=3 各簇原始特征均值对比]:

	spend_grocery	spend_fashion	spend_electronics	spend_dining	spend_online	visits_store_per_month	visits_online_per_month
Cluster_Labels_K3							
0	824.205915	311.555312	386.753100	474.753560	377.283766	4.388828	4.395400
1	591.511194	625.373134	630.916031	701.585821	836.511725	3.513993	11.927239
2	770.000000	496.666667	496.666667	620.000000	646.428571	100.000000	8.200000

图 8

[K=4 各簇原始特征均值对比]:

	spend_grocery	spend_fashion	spend_electronics	spend_dining	spend_online	visits_store_per_month	visits_online_per_month
Cluster_Labels_K4							
0	990.923567	444.267516	586.683007	716.799363	526.113180	5.979299	6.286624
1	629.184549	228.218884	263.105727	321.244635	277.184279	2.894850	3.508584
2	528.731762	639.169473	605.005754	657.351291	879.277153	2.996633	12.588103
3	770.000000	496.666667	496.666667	620.000000	646.428571	100.000000	8.200000

图 9




图 10

五、层次聚类方法

本次研究选择层次聚类方法与 K-Means 进行初步比较。

图 11 是层次聚类在 PC5 的基础上，用与 K-Means 的目标函数思路非常接近的 Ward 最小方差法输出的树状图。用“最大高度跳跃”结合 Silhouette Score、CHI、DBI、Cluster Stability、Cophenetic Correlation、Min Cluster Ratio 等多个指标综合评估（如图 12、图 13），最终选出最优 K 为 4。




图 11




图 12




图 13

通过图 14 层次聚类结果与 K-Means 结果的散点图比较，初步可以得到以下结论：K-Means 在 PCA 空间中的簇边界更清晰，四个区域分布更合理；层次聚类的红色簇（Cluster 3）与蓝色簇有大量重叠，且中心区域混杂严重，视觉上层次聚类的分离度明显更差。

K-Means vs Hierarchical Clustering — PCA Space (PC1 vs PC2)




图 14

六、两方法比较

对本研究中用到的两个方法从多个角度进行对比,详细对比结果如表 4 所示:

表 4 K-Means 和层次聚类

	K-Means (K=4)	Hierarchical (K=4)
聚类结构	4 个簇, 除簇 3 外其它三个簇结构上都比较紧密, 大小接近, 簇边界清晰	4 个簇, 除簇 1 外各簇之间有较明显的重叠, 大小分布不太均匀

簇形状	接近球形分布	有带状分布倾向
各簇规模	Cluster 0: 628 Cluster 1: 466 Cluster 2: 891 Cluster 3: 15	Cluster 0: 1076 Cluster 0: 15 Cluster 0: 415 Cluster 0: 494
Silhouette	0.3212	0.3001
CHI	938.46	847.29
DBI	0.9370	0.9676
对噪声点的处理	将噪声点（簇3）处理为一个单独的群组，与其他簇高度分离	将噪声点（簇1）处理为一个单独的群组，与其他簇高度分离
业务可解释性	四簇特征明显	主体部分的三簇间缺乏清晰的边界，特征混杂，难以命名

综合各项数据结果，K-Means（K=4）方法更适合本数据和业务场景。具体有以下理由：Silhouette 和 CHI 指标领先，聚类质量客观上更优秀；簇规模分布均衡，每个群体都有足够样本支撑后续分析；最重要的是，四个簇都对应清晰的客户行为模式，可直接映射为线下消费者、低活跃客户、线上时尚族三类可操作群体和一个异常到店客户群体，业务可解释性显著高于层次聚类产生的模糊分组。

七、客户画像

用 K-Means（K=4）方法得到 4 个簇，图 15 是客户细分特征热力图，具体客户画像如下：

Cluster 0 — “高收入线下生活品消费群体”

中年高收入已婚已育消费群体，消费重心在家庭日常刚需（杂货、餐饮），习惯线下购物方式。尽管收入最高，但时尚和线上消费潜力尚未充分释放。有钱、有家庭、偏线下的消费群体，是最具潜力的品类扩展对象，高价值客户。

Cluster 1 — “低收入低活跃沉默群体”

收入有限，消费全面保守，缺乏明显的消费偏好，线上线下均不活跃。忠诚度最低，说明与品牌连接最弱，是流失风险最高的群体，同时也是激活成本最高

的群体。

Cluster 2 — “年轻时尚线上全能消费者”

最年轻、未婚比例最高、消费自由度最大，除日常杂货外多品类高消费，忠诚度最高，收入较高的重度线上用户。是体量最大（44.6%）、价值最高的客户群体。

Cluster 3 — “极端到店异常客群”

到店频次极端异常（是其他群体的 17-35 倍），其余指标均中等。几乎可以确定不是普通消费者，可能为企业采购员、供应商或数据录入错误，建议人工核查后单独处理，不纳入常规营销策略。




图 15

八、营销建议

Cluster 2 — 年轻时尚线上全能消费者

该群体是最高价值客群，应防止竞争流失。建议根据季度消费金额或月访问次数将该群体进行会员分级，逐级对应专属权益，包括新品优先购、任意品类 9 折券及免费退换货等，持续强化品牌忠诚度；通过跨品类捆绑提升客单价，推出“生活大礼包”，如时尚类商品满 500 元赠餐厅 8 折券的方式，提升单次消费金额；设立“到店优享日”，每月一次到店购买满 1000 元，会员积分+50，将重度线上客户升级为全渠道客户。

Cluster 0 — 高收入线下生活品消费者

针对该群体要释放其时尚消费潜力，从刚需消费升级到品质消费。建议以杂货、餐饮为消费锚点，推出“家庭大礼包”，如杂货满 500 元赠时尚品类/电子

产品类折扣券等，用最强消费习惯作跳板，打开时尚品类的尝试门槛，增加电子产品消费契机；引导该群体采用线上购物方式，如 APP 首单满 300 减 80 的线上首购激励机制，赠送线上购物消费券等，逐步培养线上消费习惯。

Cluster 1 — 低收入低活跃沉默群体

该群体应该采用低成本激活方式，降低流失率。对长期未消费用户推送无门槛现金券或超低价产品，激活潜在需求，以最低成本促使第一次消费行为，打破消费惰性。

九、模型局限性

局限性：

局限性一：主成分个数选取上可能需要更多角度的对比。

局限性二：对于异常数据处理上可能存在缺陷，应该深入分析是否进入聚类分析，如果是数据错误，进入聚类后会影晌分簇的准确性。

局限性三：gender、marital_status、education_level 等类别特征未参与聚类，仅用于画像，导致当前聚类仅为消费行为差异，在客户细分上有一定影响。

改进方向：

一、数据预处理阶段增加 IQR 步骤，排除极端值干扰，确保聚类结果稳定。

二、为类别特征进行编码处理，纳入聚类计算中，实现行为和人口特征的综合分析。